

Здесь будет титульный лист, присланный из института ближе к сдаче

Использование методов глубокого обучения для предсказания кардиологических временных рядов

Оглавление

1	Введение	3
2	Обзор литературы	4
2.1	Вариабельность сердечного ритма	4
2.1.1	ЭКГ	4
2.1.2	RR	5
2.1.3	анализ HRV	6
2.2	Предсказание сна	7
2.3	Рекуррентные нейронные сети	7
2.3.1	LSTM	8
2.3.2	Разнонаправленные рекуррентные сети	9
3	Основная часть	10
3.1	Имеющиеся данные	10
3.2	Постановка задачи	10
3.3	Актуальность задачи	10
3.4	Фильтрация ЭКГ сигнала и выделение RR-пиков	11
3.4.1	Фильтрация ЭКГ	11
3.4.2	Выделение RR-пиков	11
3.5	Работа с RR-сигналом	11
3.5.1	Отбор RR-пиков	11
3.5.2	Выделение признаков	11
3.6	Проведенные эксперименты	12
3.6.1	Идентификация человека	12
3.6.2	Предсказание сна	12
3.6.3	Предсказание болезней	12
4	Заключение	13
	Список литературы	16

Глава 1

Введение

Глава 2

Обзор литературы

2.1 Вариабельность сердечного ритма

Вариабельность сердечного ритма (Heart rate variability) это явление изменения частоты сердечного ритма.

Вариабельность сердечного ритма очень сильно зависит от эмоционального [2,3] и физического [4] здоровья человека и может использоваться как его показатель.

Существуют два основных частоты колебания сердечного ритма [5].

- Колебания, вызванные дыхательной аритмией. При этом частота сердечных сокращений изменяется в связи с дыханием и можно отследить частоту дыхания.
- Низкочастотные колебания артериального давления. Это явление называется волнами Майера [6] артериального давления и, как правило, имеют частоты порядка 0,1 Гц.

Для наблюдения за сердечным ритмом применяются следующие методы:

- ЭКГ (электрокардиография) [7];
- баллистокардиография [8];
- фотоплетизмография [9].

ЭКГ считается методом, дающим наиболее четкий сигнал.

2.1.1 ЭКГ

Электрокардиограмма – это запись колебаний разности потенциалов, возникающих на поверхности возбудимой ткани или в окружающей сердце проводящей среде при распространении волны возбуждения по сердцу. [1] Запись ЭКГ производится с помощью электрокардиографов и различных систем отведений ЭКГ. Каждое отведение регистрирует разность потенциалов, существующую между двумя определенными точками электрического поля сердца, в которых установлены электроды. Пример ЭКГ можно увидеть на рис. 2.1.




Рис. 2.1. ЭКГ

Сердце обладает рядом свойств.

- Свойство автоматизма - это способность сердца вырабатывать электрические импульсы при отсутствии внешних раздражений.
- Свойство проводимости - это способность к проведению возбуждения волокон проводящей системы сердца и сократительного миокарда.
- Свойство возбудимости – это способность клеток проводящей системы сердца и сократительного миокарда возбуждаться под влиянием внешних электрических импульсов.

Возбуждение сердечной мышцы сопровождается возникновением изменяющейся разности потенциалов между наружной и внутренней поверхностью клеточной мембраны сердца.

При распространении по сердцу волны деполяризации наружная поверхность клетки приобретает отрицательный заряд, а во время реполяризации – положительный. Согласно концепции В. Эйнтховена, сердце в каждый момент сердечного цикла можно рассматривать как точечный единый диполь, который создает в окружающей его среде электрическое поле. Положительный полюс диполя (+) всегда обращен в сторону невозбужденного, а отрицательный полюс (–) – в сторону возбужденного участка сердца. 2.2




Рис. 2.2. Поле сордечного диполя в отведениях

Помещая положительный и отрицательный электроды в любые точки электрического поля, можно зарегистрировать разность потенциалов, существующую между этими точками в каждый момент деполяризации и реполяризации сердца. Конфигурация такой ЭКГ прежде всего будет зависеть от направления вектора диполя по отношению к электродам.

В настоящее время в клинической практике наиболее широко используют 12 отведений ЭКГ, запись которых является обязательной при каждом электрокардиографическом обследовании больного: 3 стандартных отведения, 3 усиленных однополюсных отведения от конечностей и 6 грудных отведений.

Стандартные отведения от конечностей регистрируют при следующем попарном подключении электродов: I отведение – левая рука (+) и правая рука (–); II отведение – левая нога (+) и правая рука (–); III отведение – левая нога (+) и левая рука (–);

2.1.2 RR

RR-интервалом называется промежуток времени между последовательными ударами сердца. Нормально частотой сердцебиения считается 60-100 ударов в минуту в состоянии покоя. Если рассматривать момент сокращения сердца более подробно [10] виден QRS-комплекс - изменения электрического потенциала, предшествующее сокращению сердца. За электрической активацией клеток (деполяризацией) следует механическое сокращение, создаваемое следующим образом. Процесс сокращения сердечных мышц состоит из следующих стадий.

- деполяризация предсердий; зубец P
- передача импульса желудочкам; интервал PR
- деполяризация желудочков; зубец R

- реполяризация желудочков; зубец Т
- мнения исследователей относительно причин происхождения зубца V различны

По длительности интервалов, глубине минимумов и высоте максимумов врачи предсказывают различные характеристики и болезни.

2.1.3 анализ HRV

Основные методы исследования HRV.

- 1 Методы основанные на анализе интервалов между сердечными ударами NN типа. При данном анализе часто подсчитываются следующие характеристики [11, 12].
 - 1.1. SDNN, стандартное отклонение интервалов NN от среднего, вычисленного почти всегда в течение 24 часов. SDNN обычно вычисляется для коротких интервалов, порядка 5 минут. SDNN отражает все циклические компоненты, ответственные за изменчивость в период записи, поэтому она представляет собой общую вариабельность.
 - 1.2. RMSSD ("среднеквадратичное последовательных различий»), квадратный корень из среднего значения квадратов последовательных разностей между соседними NN ударами.
 - 1.3. SDSD ("стандартное отклонение последовательных разностей"), стандартное отклонение последовательных разностей между соседними NNS.
 - 1.4. NN50, количество пар последовательных NN ударов, которые отличаются более чем 50 мс.
 - 1.5. pNN50, доля NN50 делится на общее количество NN ударов.
 - 1.6. NN20, количество пар последовательных NN ударов, которые отличаются более чем 20 мс.
 - 1.7. pNN20, доля NN20.
 - 1.8. EBS ("оценивается цикл дыхания"), диапазон (макс-мин) в скользящем окне заданной длительности. Окна можно перемещать без перекрытия или с перекрытием. EBS часто используют при сборе данных, где обратная связь ВСР в режиме реального времени является главной целью.
- 2 Геометрические методы [13]
- 3 Частотный анализ

Строятся гистограммы частотных характеристик NN ударов
- 4 Подсчет корреляций следующих NN ударов от предидущих [14]
- 5 Нелинейные методы [15]
 - 5.1. график Пуанкаре [16].
 - 5.2. фрактальные размерности [17].
 - 5.3. флуктуационный анализ [18]
 - 5.4. энтропия [19–21]
 - 5.5. и др. [22–24]

2.2 Предсказание сна

Сон – это естественная часть жизни каждого человека. Он происходит каждые 24 часа и занимает почти треть нашей жизни. Он состоит из последовательной смены фаз; это преимущество очень показательное качество сна, который позволяет выделить определенные патологии. Например: апноэ у пациентов с остановкой дыхания в течение ночи, и нарколептический пациентам получить доступ к сонливости в дневное время [1]. Поэтому хороший анализ сна был представлен классификация ночных этапов. По этой причине Полисомнография (ПСГ) была сделана; что является отсылкой тест для количественного определения и квалификации нарушений сна. ПСЖ представлены записи нескольких физиологических переменные во время ночного сна, для того чтобы классифицировать разные фазы сна. Действительно, эти переменные присутствуют различные характеристики в зависимости от стадии рассмотрела сна [1]. Существуют многочисленные обыски для классификации этапы сна, чтобы уменьшить время анализа, и повысить достоверность результатов диагностики. Большинство эти поиски основаны лишь на электроэнцефалограмме (ЭЭГ) [2, 3, 4]. С другой стороны, они существуют поисков основываясь на электро-миограмма (ЭМГ) и электроокулограммы (ЭОГ) [5]. В ПСЖ и другие факторы вмешаться, чтобы классифицировать различные фазы сна, которые являются: дыхание, поток воздуха, поступающего через нос и рот, сатурация кислорода в гемоглобине, электрокардиограммы (ЭКГ) и усилием грудных и мышцы живота. Запись ЭКГ является одним из самых простых и эффективных технологий в сне обнаружения нарушений. Это регулируется автономной нервной системы; этот общий источник причиной корреляции с дыханием [6] и может быть источником корреляции с разных стадий сна [7, 8, 9]. Различные исследования подтвердили, что несколько новых методов может распознать апноэ сна и стадий сна от вариабельность сердечного ритма (BCP), так как во время сна BCP представлена характеристика колебаний, связанных с сна этапах [10]. Наряду с этим, некоторые исследователи в литературе было предложено много подходов для стадий сна забил. В работе [11] предложен кардио respiratorybased постановка сна, где они используются ЭКГ, оценивается частота дыхания и дыхательный сигналов. Ссылка [12] приводится сравнение между BPC спектральный анализ и детрентного флуктуационного анализа (ДФА) применяется для сна ЭКГ. Многие другие произведения представили новый метод для изменения точки обнаружения временных рядов называется прогрессивный детрентного флуктуационного анализа (PDFA). Это метод, вдохновленный ДКА, используется для выявления изменений в минимум раз в диапазоне [13]. Недавно, [10] представляют систему, которая автоматически распознает звонок, рем и медленного в течение время сна, основываясь только на колебаниях сердечного ритма и [13] предложен способ сна и бодрствования этапы скоринга и спать оценка эффективности, используя только один-ЭКГ. Это метод основан на экстракции, по три методы; вариабельность сердечного ритма (BCP), в бестрендовый флуктуационного анализа (dfa) и windowed ДКА (WDFa). Целью данного исследования является оценка эффективности

2.3 Рекуррентные нейронные сети

Рекуррентная нейронная сеть – один из типов нейронных сетей [25], в котором присутствует обратная связь. Другими словами в выход более позднего слоя сети поступает на вход более слоя, считающегося ранее.

Рекуррентные нейронные сети имеют ряд преимуществ перед обычными.

- Разнообразные виды входных данных
- Способность строить неявные модели данных
- Устойчивость к выбросам

-

Рекуррентные сети применяются в таких задачах как:

- распознавание устной и письменной речи [26, 27];
- машинный перевод [28];
- предсказания временных рядов [29];
- И т.п.

Основной проблемой при использовании рекуррентных нейронных сетей является проблема исчезающего градиента (vanishing gradient problem [30]). Если честно подсчитывать градиент на каждой итерации обучения он будет выражаться через произведение градиентов, подсчитанных на всех предыдущих итерациях. Если градиенты были малы – наш градиент будет просто не замечен и обучение встанет надолго.

Проблема исчезающего градиента была подробно рассмотрена Хочрайтером??? (произношение) and Шмидхубера, которые разработали LSTM архитектуру [31], которая устойчива к данной проблеме. Данная архитектура оказалась проста в использовании и стала стандартным средством борьбы с исчезающим градиентом. Также были осуществлены попытки других способов решения данной проблемы:

- обратное распространение во времени (Backpropagation through time) [32]. Используется для обучения сетей Элмана.
- использование мощного secondorder алгоритмы оптимизации (Martens, 2010; Мартенс Sutskever, 2011)
- регуляризация весов в RNN, что гарантирует, что градиент не обращается в нуль (Pascanu др., 2012)
- отказ от всего обучения текущие веса (Jaeger, Haas, 2004; Jaeger, 2001), и очень осторожны инициализации параметров РНН (в Sutskever др., 2013).

Также была обнаружена проблема сильного возрастания градиента, но она легко решилась ограничением на модуль градиента.

2.3.1 LSTM

Данный слой успешно борется с проблемой исчезающего градиента. Каждый нейрон в данном слое представляет собой "ячейку памяти" (рис. 2.3). Данные ячейки организованы для хранения информации и позволяют более качественно обрабатывать длинные входные последовательности.

Пускай на вход LSTM ячейке памяти подается часть входной последовательности $x_t = (x_1, \dots, x_N)$ и предыдущие выходные векторы признаков $h_{t-1} = (h_1, \dots, h_M)$. Ячейка должна подсчитать вектор признаков h_t . Ячейка организована следующим образом:

$$i_t = \sigma(W_{xi} * x_t + W_{hi} * h_{t-1} + W_{ci} * c_{t-1} + b_i) \quad (2.1)$$

$$f_t = \sigma(W_{xf} * x_t + W_{hf} * h_{t-1} + W_{cf} * c_{t-1} + b_f) \quad (2.2)$$

$$c_t = f_t * c_{t-1} + i_t * \tanh(W_{xc} * x_{t-1} + W_{hc} * h_{t-1} + b_c) \quad (2.3)$$

$$o_t = \sigma(W_{xo} * x_t + W_{ho} * h_{t-1} + W_{co} * c_t + b_o) \quad (2.4)$$

$$h_t = o_t * \tanh(c_t) \quad (2.5)$$

Здесь $\sigma = \frac{1}{1+e^{-x}}$ - сигмоида, логистическая функция, принимающая значения от 0 до 1. А i , f , o и c - вход ячейки, клетка памяти, выход ячейки и клетка активации, по содержимому которой решается, будет ли использоваться вектор из клетки памяти. Все вышеперечисленные векторы имеют размерность h_t .




Рис. 2.3. LSTM ячейка

2.3.2 Разнонаправленные рекуррентные сети

Глава 3

Основная часть

3.1 Имеющиеся данные

В рамках программы SAnR были записаны ЭКГ (использовалось только первое отведение) 1800 москвичей преклонного возраста (55-91 год). Из них 46% мужчин. Запись каждого ЭКГ производилась в течение суток. В это же время за человеком велось дополнительное наблюдение и было известно, в какой промежуток времени он спал, а в какой - бодрствовал. Также про каждого человека известна некоторая информация: состояние здоровья, вес, курит ли он и многое другое.

3.2 Постановка задачи

Цель работы - анализируя данные ЭКГ предсказать в какое время человек спал/бодрствовал, исследовать возможность предсказания болезней и самочувствия человека. Также в рамках обучения выделения признаков и их анализа были проведены исследования по идентификации человека.

3.3 Актуальность задачи

Электрокардиография - самый распространенный клинический инструмент, который измеряет электрическую деятельность сердца с поверхности тела. Сигнал ЭКГ, или проще variability сердечного ритма содержит много интересной информации о человеке. Процесс получения информации об ЭКГ у людей стал простым !!!!!!!(более технически простым) с изобретения новых технологий и приборов, таких как фитнес-браслеты, специальные чехлы для телефонов, мониторы-холтеры и т. д. Также создание базы данных, собранных в дополнение к существующим (SAnR, AHA DB, ESC DB и т. д.). в настоящее время.

Процесс сна имеет важное значение для медицинской диагностики. Классическая полисомнография для мониторинга сна накладывает существенные ограничения на практике. В последние годы, носимых устройств для мониторинга здоровья становится все более популярными. Браслеты и смарт-часы позволяют пациенту быть подвижным, в то время как необходимые данные собираются в своей естественной среде. Однако, на сегодняшний день нет хороших научных доказательств, представленных публике, о том, что эти устройства могут оценить продолжительность сна с высокой точностью.

3.4 Фильтрация ЭКГ сигнала и выделение RR-пиков

3.4.1 Фильтрация ЭКГ

К экг сигналу применялся ряд фильтров: фильтры высоких и низких частот. тут будет картинки 4.

3.4.2 Выделение RR-пиков

Для определения RR-пиков использовался следующий алгоритм.

- 1 На протяжении 200мс бралась точка максимального участка сигнала.
- 2 Справа от него в течение 5 мс бралась минимальная точка и проверялось, что это локальный минимум.
- 3 Разница высот между минимумом и максимумом должна быть больше порогового значения.
- 4 Проверялось, что слева от максимума в пределах 20 мс также можно найти точку, меньше чем максимум для заданного значения

!!!иллюстрация алгоритма

3.5 Работа с RR-сигналом

3.5.1 Отбор RR-пиков

Для классификации промежутков времени на сон/бодрствование необходим весь временной ряд. Но для идентификации человека, для предсказания каких-либо характеристик достаточно только его части. Если брать для предсказания характеристик небольшие участки сигнала размер обучающей выборки увеличится в несколько раз, увеличится ее обобщающая способность.

То, что мы берем только участки сигнала позволяет нам отобрать участки с минимумом шума. На сигнал могут влиять случайные движения человека, произвольные сокращения мышц. Может быть не очень хорошо закреплен электрод или же он может сдвинуться или отойти на время. в первом случае мы получаем лишние пики, во втором, наоборот, долгий промежуток без них.

Было решено отбирать участки сигнала где все выделенные R-пики удовлетворяют следующим условиям:

- RR интервалы больше 200 миллисекунд
- RR интервалы меньше 2 секунд
- разница высот соседних пиков менее 20%
- разница продолжительностей соседних RR интервалов менее 20%

3.5.2 Выделение признаков

Признаки!много) Большая часть подсчитываемых признаков по выделенным R пикам описана в обзоре литературы - они являются стандартными при работе в ЭКГ сигналом. Однако вдобавок к ним использовались еще добавочные признаки.

- амплитуды пиком и минимумов в QRS-комплексе

- разница высот между пиками P, R, T
- отношения высот P, R, T
- средние значения на промежутках PQ, QR, QT
- длительность различных фаз в QRS-комплексе
- площадь под графиком на промежутках PQ, QS, ST, begin-Q, S-final

В медицине утверждается [!! ссылки], что врачи ориентируются на данные параметры при постановки диагноза.

3.6 Проведенные эксперименты

В рамках данного исследования проводились попытки решения следующих задач.

3.6.1 Идентификация человека

Люди делились на 3 выборки: тестовую, валидационную и обучающую. ЭКГ каждого человека нарезались на отрезки. Состоялись пары отрезков, для каждой пары устанавливалось из одного сигнала они взяты (1) или из разных (0). Далее пары отрезков подавались на вход сети : архитектуру? надо ли вообще. я об этом так себе знаю - это твое исследование было Качество предсказания на тестовом датасете - 75%. Количество элементов каждого класса во всех выборках было равным.

3.6.2 Предсказание сна

Предсказание сна - актуальная задача по следующим причинам. В ходе данного исследования рассматривались следующие методы

Линейный классификатор

Если смотреть на RR-сигнал во время сна и бодрствования (две картинки сюда) можно заметить, что во время сна частота пульса уменьшается (достаточно очевидное предположение известное всем). Также на большей части ЭКГ уменьшается дисперсия сигнала во время сна. Первым предложенным алгоритмом был следующий.

- 1 для сигнала подсчитывались среднее значение и дисперсия
- 2 маркируются все точки сигнала на три категории
 - точки на половину дисперсии больше среднего значения
 - точки на половину дисперсии меньше среднего значения
 - все остальные точки (формулой бы?)

3

3.6.3 Предсказание болезней

Глава 4

Заключение

Литература

1. АНДРЕЙ ВЛАДИСЛАВОВИЧ Струтынский. Электрокардиограмма: Анализ и интерпретация. М., Медпресс-информ, 2009.
2. Peter Nickel and Friedhelm Nachreiner. Sensitivity and diagnosticity of the 0.1-hz component of heart rate variability as an indicator of mental workload. *Human Factors: The Journal of the Human Factors and Ergonomics Society*, 45(4):575–590, 2003.
3. Peter Jönsson. Respiratory sinus arrhythmia as a function of state anxiety in healthy individuals. *International journal of psychophysiology*, 63(1):48–54, 2007.
4. J Th Bigger, Joseph L Fleiss, Richard C Steinman, Linda M Rolnitzky, Robert E Kleiger, and Jeffrey N Rottman. Frequency domain measures of heart period variability and mortality after myocardial infarction. *Circulation*, 85(1):164–171, 1992.
5. B. McA Sayers. Analysis of heart rate variability. *Ergonomics*, 16(1):17–32, 1973.
6. Claude Julien. The enigma of mayer waves: facts and models. *Cardiovascular research*, 70(1):12–21, 2006.
7. Ю. И. Зудбинов. АЗБУКА ЭКГ. Феникс, Ростов-на-дону, 2003.
8. C. Bruser, K. Stadlthanner, S. de Waele, and S. Leonhardt. Adaptive beat-to-beat heart rate estimation in ballistocardiograms. *Information Technology in Biomedicine, IEEE Transactions on*, 15(5):778–786, Sept 2011.
9. John Allen. Photoplethysmography and its application in clinical physiological measurement. *Physiological Measurement*, 28(3):R1, 2007.
10. АВ Струтынский. Электрокардиограмма: анализ и интерпретация. М.: ООО «МЕД-пресс», 1999.
11. JE Mietus, CK Peng, I Henry, RL Goldsmith, and AL Goldberger. The pnnx files: re-examining a widely used heart rate variability measure. *Heart*, 88(4):378–380, 2002.
12. Clinton F Goss and Eric B Miller. Dynamic metrics of heart rate variability. *arXiv preprint arXiv:1308.6018*, 2013.
13. Luiz Carlos Marques Vanderlei, Carlos Marcelo Pastre, Ismael Forte Freitas Júnior, and Moacir Fernandes de Godoy. Geometric indexes of heart rate variability in obese and eutrophic children. *Arquivos brasileiros de cardiologia*, 95(1):35–40, 2010.
14. C-K Peng, J Mietus, JM Hausdorff, S Havlin, H Eugene Stanley, and AL Goldberger. Long-range anticorrelations and non-gaussian behavior of the heartbeat. *Physical review letters*, 70(9):1343, 1993.
15. Jørgen K Kanters, NIELS-HENRIK HOLSTEIN-RATHLOU, and Erik Agner. Lack of evidence for low-dimensional chaos in heart rate variability. *Journal of cardiovascular electrophysiology*, 5(7):591–601, 1994.

16. PW Kamen and AM Tonkin. Application of the poincare plot to heart rate variability: a new measure of functional status in heart failure. *Australian and New Zealand journal of medicine*, 25(1):18–26, 1995.
17. Peter Grassberger and Itamar Procaccia. Measuring the strangeness of strange attractors. In *The Theory of Chaotic Attractors*, pages 170–189. Springer, 2004.
18. Jan W Kantelhardt, Eva Koscielny-Bunde, Henio HA Rego, Shlomo Havlin, and Armin Bunde. Detecting long-range correlations with detrended fluctuation analysis. *Physica A: Statistical Mechanics and its Applications*, 295(3):441–454, 2001.
19. Robert J Storella, Harrison W Wood, Kenneth M Mills, Jørgen K Kanters, Michael V Højgaard, and Niels-Henrik Holstein-Rathlou. Approximate entropy and point correlation dimension of heart rate variability in healthy subjects. *Integrative physiological and behavioral science*, 33(4):315–320, 1998.
20. Joshua S Richman and J Randall Moorman. Physiological time-series analysis using approximate entropy and sample entropy. *American Journal of Physiology-Heart and Circulatory Physiology*, 278(6):H2039–H2049, 2000.
21. Madalena Costa, Ary L Goldberger, and C-K Peng. Multiscale entropy analysis of complex physiologic time series. *Physical review letters*, 89(6):068102, 2002.
22. Boris P Kovatchev, Leon S Farhy, Hanqing Cao, M Pamela Griffin, Douglas E Lake, and J Randall Moorman. Sample asymmetry analysis of heart rate characteristics with application to neonatal sepsis and systemic inflammatory response syndrome. *Pediatric research*, 54(6):892–898, 2003.
23. Amir H Shirazi, Mohammad R Raoufy, Haleh Ebadi, Michele De Rui, Sami Schiff, Roham Mazloom, Sohrab Hajizadeh, Shahriar Gharibzadeh, Ahmad R Dehpour, Piero Amodio, et al. Quantifying memory in complex physiological time-series. *PloS one*, 8(9):e72854, 2013.
24. H Ebadi, AH Shirazi, Ali R Mani, and GR Jafari. Inverse statistical approach in heartbeat time series. *Journal of Statistical Mechanics: Theory and Experiment*, 2011(08):P08014, 2011.
25. Raúl Rojas. *Neural networks: a systematic introduction*. Springer Science & Business Media, 2013.
26. Alan Graves, Abdel-rahman Mohamed, and Geoffrey Hinton. Speech recognition with deep recurrent neural networks. In *Acoustics, Speech and Signal Processing (ICASSP), 2013 IEEE International Conference on*, pages 6645–6649. IEEE, 2013.
27. Ronaldo Messina and Jérôme Louradour. Segmentation-free handwritten chinese text recognition with lstm-rnn. In *Document Analysis and Recognition (ICDAR), 2015 13th International Conference on*, pages 171–175. IEEE, 2015.
28. Kyunghyun Cho, Bart Van Merriënboer, Caglar Gulcehre, Dzmitry Bahdanau, Fethi Bougares, Holger Schwenk, and Yoshua Bengio. Learning phrase representations using rnn encoder-decoder for statistical machine translation. *arXiv preprint arXiv:1406.1078*, 2014.
29. Sharat C Prasad and Piyush Prasad. Deep recurrent neural networks for time series prediction. *arXiv preprint arXiv:1407.5949*, 2014.
30. Sepp Hochreiter. The vanishing gradient problem during learning recurrent neural nets and problem solutions. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, 6(02):107–116, 1998.

31. Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, 9(8):1735–1780, 1997.
32. Michael C Mozer. A focused back-propagation algorithm for temporal pattern recognition. *Complex systems*, 3(4):349–381, 1989.