

Здесь будет титульный лист, присланный из института ближе к сдаче

Использование методов глубокого обучения для предсказания кардиологических временных рядов

Оглавление

1	Введение	3
2	Обзор литературы	4
2.1	Вариабельность сердечного ритма	4
2.1.1	ЭКГ	4
2.1.2	Обработка ЭКГ	5
2.1.3	анализ HRV	5
2.2	Рекуррентные нейронные сети	6
2.2.1	LSTM	7
2.2.2	Разнонаправленные рекуррентные сети	7
3	Основная часть	8
4	Заключение	9
	Список литературы	12

Глава 1

Введение

Глава 2

Обзор литературы

2.1 Вариабельность сердечного ритма

Вариабельность сердечного ритма (Heart rate variability) это явление изменения частоты сердечного ритма.

Вариабельность сердечного ритма очень сильно зависит от эмоционального [1, 2] и физического [3] здоровья человека и может использоваться как его показатель.

Существуют два основных частоты колебания сердечного ритма [4].

- Колебания, вызванные дыхательной аритмией. При этом частота сердечных сокращений изменяется в связи с дыханием и можно отследить частоту дыхания.
- Низкочастотные колебания артериального давления. Это явление называется волнами Майера [5] артериального давления и, как правило, имеют частоты порядка 0,1 Гц.

Для наблюдения за сердечным ритмом применяются следующие методы:

- ЭКГ (электрокардиография) [6];
- баллистокардиография [7];
- фотоплетизмография [8].

ЭКГ считается методом, дающим наиболее четкий сигнал.

2.1.1 ЭКГ

Электрокардиография измеряет электрическую активность сердца за некоторый период времени с помощью электродов, наложенных на различные участки сердца. Электроды сквозь кожу регистрируют слабый электрический сигнал, вызываемый сердцебиением. Обычно 10 электродов располагаются на груди и конечностях пациента. С их помощью измеряются общая величина электрического потенциала и его направление. График зависимости потенциала от времени называется электрокардиограммой. Ее пример можно увидеть на рис. 2.1.




Рис. 2.1. ЭКГ

RR-интервалом называется промежуток времени между последовательными ударами сердца. Нормально частотой сердцебиения считается 60-100 ударов в минуту в состоянии покоя. Если рассматривать момент сокращения сердца более подробно [9] виден QRS-комплекс - изменения электрического потенциала, предшествующее сокращению сердца. а электрической активацией клеток (деполяризацией) следует механическое сокращение, создаваемое следующим образом. Процесс сокращения сердечных мышц состоит из следующих стадий.

- деполяризация предсердий; зубец P
- передача импульса желудочкам; интервал PR
- деполяризация желудочков; зубец R
- реполяризация желудочков; зубец T
- мнения исследователей относительно причин происхождения зубца V различны

2.1.2 Обработка ЭКГ

2.1.3 анализ HRV

Основные методы исследования HRV.

1 Методы основанные на анализе интервалов между сердечными ударами NN типа. При данном анализе часто подсчитываются следующие характеристики [10, 11].

- 1.1. SDNN, стандартное отклонение интервалов NN от среднего, вычисленного почти всегда в течение 24 часов. SDNN обычно вычисляется для коротких интервалов, порядка 5 минут. SDNN отражает все циклические компоненты, ответственные за изменчивость в период записи, поэтому она представляет собой общую вариабельность.
- 1.2. RMSSD ("среднеквадратичное последовательных различий"), квадратный корень из среднего значения квадратов последовательных разностей между соседними NN ударами.
- 1.3. SDSD ("стандартное отклонение последовательных разностей"), стандартное отклонение последовательных разностей между соседними NNS.
- 1.4. NN50, количество пар последовательных NN ударов, которые отличаются более чем 50 мс.
- 1.5. pNN50, доля NN50 делится на общее количество NN ударов.
- 1.6. NN20, количество пар последовательных NN ударов, которые отличаются более чем 20 мс.
- 1.7. pNN20, доля NN20.
- 1.8. EBS ("оценивается цикл дыхания"), диапазон (макс-мин) в скользящем окне заданной длительности. Окна можно перемещать без перекрытия или с перекрытием. EBS часто используют при сборе данных, где обратная связь ВСР в режиме реального времени является главной целью.

2 Геометрические методы [12]

3 Частотный анализ

Строятся гистограммы частотных характеристик NN ударов

4 Подсчет корреляций следующих NN ударов от предыдущих [13]

5 Нелинейные методы [14]

- 5.1. график Пуанкаре [15].
- 5.2. фрактальные размерности [16].
- 5.3. флуктуационный анализ [17]
- 5.4. энтропия [18–20]
- 5.5. и др. [21–23]

2.2 Рекуррентные нейронные сети

Рекуррентная нейронная сеть – один из типов нейронных сетей [24], в котором присутствует обратная связь. Другими словами в выход более позднего слоя сети поступает на вход более слоя, считающегося ранее.

Рекуррентные нейронные сети имеют ряд преимуществ перед обычными.

- Разнообразные виды входных данных
- Способность строить неявные модели данных
- Устойчивость к выбросам
-

Рекуррентные сети применяются в таких задачах как:

- распознавание устной и письменной речи [25, 26];
- машинный перевод [27];
- предсказания временных рядов [28];
- И т.п.

Основной проблемой при использовании рекуррентных нейронных сетей является проблема исчезающего градиента (vanishing gradient problem [29]). Если честно подсчитывать градиент на каждой итерации обучения он будет выражаться через произведение градиентов, подсчитанных на всех предыдущих итерациях. Если градиенты были малы – наш градиент будет просто не замечен и обучение встанет надолго.

Проблема исчезающего градиента была подробно рассмотрена Хочрайтером??? (произношение) and Шмидхубера, которые разработали LSTM архитектуру [30], которая устойчива к данной проблеме. Данная архитектура оказалась проста в использовании и стала стандартным средством борьбы с исчезающим градиентом. Также были осуществлены попытки других способов решения данной проблемы:

- обратное распространение во времени (Backpropagation through time) [31]. Используется для обучения сетей Элмана.
- использование мощного secondorder алгоритмы оптимизации (Martens, 2010; Мартенс Sutskever, 2011)
- регуляризация весов в RNN, что гарантирует, что градиент не обращается в нуль (Pascanu др., 2012)
- отказ от всего обучения текущие веса (Jaeger, Haas, 2004; Jaeger, 2001), и очень осторожны инициализации параметров RNN (в Sutskever др., 2013).

Также была обнаружена проблема сильного возрастания градиента, но она легко решилась ограничением на модуль градиента.

2.2.1 LSTM

Данный слой успешно борется с проблемой исчезающего градиента. Каждый нейрон в данном слое представляет собой "ячейку памяти" (рис. 2.2). Данные ячейки организованы для хранения информации и позволяют более качественно обрабатывать длинные входные последовательности.




Рис. 2.2. LSTM ячейка

Пусть на вход LSTM ячейке памяти подается часть входной последовательности $x_t = (x_1, \dots, x_N)$ и предыдущие выходные векторы признаков $h_{t-1} = (h_1, \dots, h_M)$. Ячейка должна подсчитать вектор признаков h_t . Ячейка организована следующим образом:

$$i_t = \sigma(W_{xi} * x_t + W_{hi} * h_{t-1} + W_{ci} * c_{t-1} + b_i) \quad (2.1)$$

$$f_t = \sigma(W_{xf} * x_t + W_{hf} * h_{t-1} + W_{cf} * c_{t-1} + b_f) \quad (2.2)$$

$$c_t = f_t * c_{t-1} + i_t * \tanh(W_{xc} * x_t + W_{hc} * h_{t-1} + b_c) \quad (2.3)$$

$$o_t = \sigma(W_{xo} * x_t + W_{ho} * h_{t-1} + W_{co} * c_t + b_o) \quad (2.4)$$

$$h_t = o_t * \tanh(c_t) \quad (2.5)$$

Здесь $\sigma = \frac{1}{1+e^{-x}}$ - сигмоида, логистическая функция, принимающая значения от 0 до 1. А i , f , o и c - вход ячейки, клетка памяти, выход ячейки и клетка активации, по содержимому которой решается, будет ли использоваться вектор из клетки памяти. Все вышеперечисленные вектора имеют размерность h_t .

2.2.2 Разнонаправленные рекуррентные сети

Глава 3

Основная часть

3.1 Фильтрация ЭКГ сигнала и выделение RR-пиков

3.1.1 Фильтрация ЭКГ

3.1.2 Выделение RR-пиков

3.2 Работа с RR-сигналом

3.2.1 Отбор RR-пиков

3.2.2 Выделение признаков

3.3 Проведенные эксперименты

3.3.1 Идентификация человека

3.3.2 Предсказание сна

3.3.3 Предсказание болезней

Глава 4

Заключение

Литература

1. Peter Nickel and Friedhelm Nachreiner. Sensitivity and diagnosticity of the 0.1-hz component of heart rate variability as an indicator of mental workload. *Human Factors: The Journal of the Human Factors and Ergonomics Society*, 45(4):575–590, 2003.
2. Peter Jönsson. Respiratory sinus arrhythmia as a function of state anxiety in healthy individuals. *International journal of psychophysiology*, 63(1):48–54, 2007.
3. J Th Bigger, Joseph L Fleiss, Richard C Steinman, Linda M Rolnitzky, Robert E Kleiger, and Jeffrey N Rottman. Frequency domain measures of heart period variability and mortality after myocardial infarction. *Circulation*, 85(1):164–171, 1992.
4. B. McA Sayers. Analysis of heart rate variability. *Ergonomics*, 16(1):17–32, 1973.
5. Claude Julien. The enigma of mayer waves: facts and models. *Cardiovascular research*, 70(1):12–21, 2006.
6. Ю. И. Зудбинов. *АЗБУКА ЭКГ*. Феникс, Ростов-на-дону, 2003.
7. C. Bruser, K. Stadlthanner, S. de Waele, and S. Leonhardt. Adaptive beat-to-beat heart rate estimation in ballistocardiograms. *Information Technology in Biomedicine, IEEE Transactions on*, 15(5):778–786, Sept 2011.
8. John Allen. Photoplethysmography and its application in clinical physiological measurement. *Physiological Measurement*, 28(3):R1, 2007.
9. АВ Струтынский. Электрокардиограмма: анализ и интерпретация. М.: ООО «МЕД-пресс», 1999.
10. JE Mietus, CK Peng, I Henry, RL Goldsmith, and AL Goldberger. The pnnx files: re-examining a widely used heart rate variability measure. *Heart*, 88(4):378–380, 2002.
11. Clinton F Goss and Eric B Miller. Dynamic metrics of heart rate variability. *arXiv preprint arXiv:1308.6018*, 2013.
12. Luiz Carlos Marques Vanderlei, Carlos Marcelo Pastre, Ismael Forte Freitas Júnior, and Moacir Fernandes de Godoy. Geometric indexes of heart rate variability in obese and eutrophic children. *Arquivos brasileiros de cardiologia*, 95(1):35–40, 2010.
13. C-K Peng, J Mietus, JM Hausdorff, S Havlin, H Eugene Stanley, and AL Goldberger. Long-range anticorrelations and non-gaussian behavior of the heartbeat. *Physical review letters*, 70(9):1343, 1993.
14. Jørgen K Kanters, NIELS-HENRIK HOLSTEIN-RATHLOU, and Erik Agner. Lack of evidence for low-dimensional chaos in heart rate variability. *Journal of cardiovascular electrophysiology*, 5(7):591–601, 1994.

15. PW Kamen and AM Tonkin. Application of the poincare plot to heart rate variability: a new measure of functional status in heart failure. *Australian and New Zealand journal of medicine*, 25(1):18–26, 1995.
16. Peter Grassberger and Itamar Procaccia. Measuring the strangeness of strange attractors. In *The Theory of Chaotic Attractors*, pages 170–189. Springer, 2004.
17. Jan W Kantelhardt, Eva Koscielny-Bunde, Henio HA Rego, Shlomo Havlin, and Armin Bunde. Detecting long-range correlations with detrended fluctuation analysis. *Physica A: Statistical Mechanics and its Applications*, 295(3):441–454, 2001.
18. Robert J Storella, Harrison W Wood, Kenneth M Mills, Jørgen K Kanters, Michael V Højgaard, and Niels-Henrik Holstein-Rathlou. Approximate entropy and point correlation dimension of heart rate variability in healthy subjects. *Integrative physiological and behavioral science*, 33(4):315–320, 1998.
19. Joshua S Richman and J Randall Moorman. Physiological time-series analysis using approximate entropy and sample entropy. *American Journal of Physiology-Heart and Circulatory Physiology*, 278(6):H2039–H2049, 2000.
20. Madalena Costa, Ary L Goldberger, and C-K Peng. Multiscale entropy analysis of complex physiologic time series. *Physical review letters*, 89(6):068102, 2002.
21. Boris P Kovatchev, Leon S Farhy, Hanqing Cao, M Pamela Griffin, Douglas E Lake, and J Randall Moorman. Sample asymmetry analysis of heart rate characteristics with application to neonatal sepsis and systemic inflammatory response syndrome. *Pediatric research*, 54(6):892–898, 2003.
22. Amir H Shirazi, Mohammad R Raoufy, Haleh Ebadi, Michele De Rui, Sami Schiff, Roham Mazloom, Sohrab Hajizadeh, Shahriar Gharibzadeh, Ahmad R Dehpour, Piero Amodio, et al. Quantifying memory in complex physiological time-series. *PloS one*, 8(9):e72854, 2013.
23. H Ebadi, AH Shirazi, Ali R Mani, and GR Jafari. Inverse statistical approach in heartbeat time series. *Journal of Statistical Mechanics: Theory and Experiment*, 2011(08):P08014, 2011.
24. Raúl Rojas. *Neural networks: a systematic introduction*. Springer Science & Business Media, 2013.
25. Alan Graves, Abdel-rahman Mohamed, and Geoffrey Hinton. Speech recognition with deep recurrent neural networks. In *Acoustics, Speech and Signal Processing (ICASSP), 2013 IEEE International Conference on*, pages 6645–6649. IEEE, 2013.
26. Ronaldo Messina and Jérôme Louradour. Segmentation-free handwritten chinese text recognition with lstm-rnn. In *Document Analysis and Recognition (ICDAR), 2015 13th International Conference on*, pages 171–175. IEEE, 2015.
27. Kyunghyun Cho, Bart Van Merriënboer, Caglar Gulcehre, Dzmitry Bahdanau, Fethi Bougares, Holger Schwenk, and Yoshua Bengio. Learning phrase representations using rnn encoder-decoder for statistical machine translation. *arXiv preprint arXiv:1406.1078*, 2014.
28. Sharat C Prasad and Piyush Prasad. Deep recurrent neural networks for time series prediction. *arXiv preprint arXiv:1407.5949*, 2014.
29. Sepp Hochreiter. The vanishing gradient problem during learning recurrent neural nets and problem solutions. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, 6(02):107–116, 1998.

30. Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, 9(8):1735–1780, 1997.
31. Michael C Mozer. A focused back-propagation algorithm for temporal pattern recognition. *Complex systems*, 3(4):349–381, 1989.