

Здесь будет титульный лист, присланный из института ближе к сдаче

Использование методов глубокого обучения для предсказания кардиологических временных рядов

Оглавление

1	Введение	3
2	Обзор литературы	4
2.1	Вариабельность сердечного ритма	4
2.1.1	ЭКГ	4
2.1.2	анализ ЭКГ	4
2.2	Рекуррентные нейронные сети	5
2.2.1	LSTM	6
2.2.2	Разнонаправленные рекуррентные сети	7
3	Основная часть	8
	Список литературы	11

Глава 1

Введение

Глава 2

Обзор литературы

2.1 Вариабельность сердечного ритма

Вариабельность сердечного ритма (Heart rate variability) является явлением изменения частоты пульса.

ЭКГ считается наилучшим методом, данный метод обеспечивает наиболее четкий сигнал.

Вариабельность сердечного ритма очень сильно зависит от эмоционального [5,6] и физического [7] здоровья индивидуума.

Существуют два основных типа колебания сердечного ритма [8].

- Колебания из-зи дыхательной аритмии (или дыхательной синусоидальная аритмия). При этом частота сердечных сокращений изменяется в связи с дыханием и можно отследить частоту дыхания.
- Низкочастотные колебания. Это изменение частоты сердечных сокращений связана с волнами Майера [9] артериального давления и, как правило, имеют частоты порядка 0,1 Гц.

Для анализа сердечного ритма используются следующие методы наблюдения за сердцебиением:

- ЭКГ (электрокардиограмма) [2];
- балистокардиография [3];
- фотоплетизмограмма [4].

2.1.1 ЭКГ

здесь будет немного о физике ЭКГ

2.1.2 анализ HRV

Основные методы исследования HRV.

- 1 Методы основанные на анализе интервалов между сердечными ударами NN типа. При данном анализе часто подсчитываются следующие характеристики [10, 11].

- 1.1. SDNN, стандартное отклонение интервалов NN от среднего, вычисленного почти всегда в течение 24 часов. SDNN обычно вычисляется для коротких интервалов, порядка 5 минут. SDNN отражает все циклические компоненты, ответственные за изменчивость в период записи, поэтому она представляет собой общую вариабельность.

- 1.2. RMSSD ("среднеквадратичное последовательных различий"), квадратный корень из среднего значения квадратов последовательных разностей между соседними NN ударами.
- 1.3. SDD ("стандартное отклонение последовательных разностей"), стандартное отклонение последовательных разностей между соседними NN.
- 1.4. NN50, количество пар последовательных NN ударов, которые отличаются более чем 50 мс.
- 1.5. pNN50, доля NN50 делится на общее количество NN ударов.
- 1.6. NN20, количество пар последовательных NN ударов, которые отличаются более чем 20 мс.
- 1.7. pNN20, доля NN20.
- 1.8. EBS ("оценивается цикл дыхания"), диапазон (макс-мин) в скользящем окне заданной длительности. Окна можно перемещать без перекрытия или с перекрытием. EBS часто используют при сборе данных, где обратная связь ВСП в режиме реального времени является главной целью.

2 Геометрические методы [12]

3 Частотный анализ

Строятся гистограммы частотных характеристик NN ударов

4 Подсчет корреляций следующих NN ударов от предыдущих [13]

5 Нелинейные методы [14]

- 5.1. график Пуанкаре [15].
- 5.2. фрактальные размерности [16].
- 5.3. флуктуационный анализ [17]
- 5.4. энтропия [18–20]
- 5.5. и др. [21–23]

2.2 Рекуррентные нейронные сети

Рекуррентная нейронная сеть – один из типов нейронных сетей [24], в котором присутствует обратная связь. Другими словами в выход более позднего слоя сети поступает на вход более слоя, считающегося ранее.

Рекуррентные нейронные сети имеют ряд преимуществ перед обычными.

- Разнообразные виды входных данных
- Способность строить неявные модели данных
- Устойчивость к выбросам
-

Рекуррентные сети применяются в таких задачах как:

- распознавание устной и письменной речи [25, 26];
- машинный перевод [27];

- предсказания временных рядов [28];
- И т.п.

Основной проблемой при использовании рекуррентных нейронных сетей является проблема исчезающего градиента (vanishing gradient problem [29]). Если честно подсчитывать градиент на каждой итерации обучения он будет выражаться через произведение градиентов, подсчитанных на всех предыдущих итерациях. Если градиенты были малы – наш градиент будет просто не замечен и обучение встанет надолго.

Проблема исчезающего градиента была подробно рассмотрена Хочрайтером (Hochreiter) and Шмидхубера, которые разработали LSTM архитектуру [30], которая устойчива к данной проблеме. Данная архитектура оказалась проста в использовании и стала стандартным средством борьбы с исчезающим градиентом. Также были осуществлены попытки других способов решения данной проблемы:

- обратное распространение во времени (Backpropagation through time) [31]. Используется для обучения сетей Элмана.
- использование мощного secondorder алгоритмы оптимизации (Martens, 2010; Мартенс Sutskever, 2011)
- регуляризация весов в RNN, что гарантирует, что градиент не обращается в нуль (Pascanu др., 2012)
- отказ от всего обучения текущие веса (Jaeger, Haas, 2004; Jaeger, 2001), и очень осторожны инициализации параметров РНН (в Sutskever др., 2013).

Также была обнаружена проблема сильного возрастания градиента, но она легко решилась ограничением на модуль градиента.

2.2.1 LSTM

Данный слой успешно борется с проблемой исчезающего градиента. Каждый нейрон в данном слое представляет собой "ячейку памяти" (2.1). Данные ячейки организованы для хранения информации и позволяют более качественно обрабатывать длинные входные последовательности.




Рис. 2.1. LSTM ячейка

Пусть на вход LSTM ячейке памяти подается часть входной последовательности $x_t = (x_1, \dots, x_N)$ и предыдущий выходной вектор признаков $h_{t-1} = (h_1, \dots, h_M)$. Ячейка должна подсчитать вектор признаков h_t . Ячейка организована следующим образом:

$$i_i = \sigma(W_{xi} * x_t + W_{hi} * h_{t-1} + W_{ci} * c_{t-1} + b_i) \quad (2.1)$$

$$f_t = \sigma(W_{xf} * x_t + W_{hf} * h_{t-1} + W_{cf} * c_{t-1} + b_f) \quad (2.2)$$

$$c_t = f_t * c_{t-1} + i_t * \tanh(W_{xc} * x_{t-1} + W_{hc} * h_{t-1} + b_c) \quad (2.3)$$

$$o_t = \sigma(W_{xo} * x_t + W_{ho} * h_{t-1} + W_{co} * c_t + b_o) \quad (2.4)$$

$$h_t = o_t * \tanh(c_t) \quad (2.5)$$

Здесь $\sigma = \frac{1}{1+e^{-x}}$ - сигмоида, логистическая функция, принимающая значения от 0 до 1. А i, f, o и c - вход ячейки, клетка памяти, выход ячейки и клетка активации, по содержимому которой решается, будет ли использоваться вектор из клетки памяти. Все вышеперечисленные вектора имеют размерность h_t .

2.2.2 Разнонаправленные рекуррентные сети

Глава 3

Основная часть

Литература

1. Андрей Игнатов. Глубокое обучение в задаче информационного анализа электрокардиограмм для диагностики заболеваний.
2. Ю. И. Зудбинов. *АЗБУКА ЭКГ*. Феникс, Ростов-на-дону, 2003.
3. C. Bruser, K. Stadlthanner, S. de Waele, and S. Leonhardt. Adaptive beat-to-beat heart rate estimation in ballistocardiograms. *Information Technology in Biomedicine, IEEE Transactions on*, 15(5):778–786, Sept 2011.
4. John Allen. Photoplethysmography and its application in clinical physiological measurement. *Physiological Measurement*, 28(3):R1, 2007.
5. Peter Nickel and Friedhelm Nachreiner. Sensitivity and diagnosticity of the 0.1-hz component of heart rate variability as an indicator of mental workload. *Human Factors: The Journal of the Human Factors and Ergonomics Society*, 45(4):575–590, 2003.
6. Peter Jönsson. Respiratory sinus arrhythmia as a function of state anxiety in healthy individuals. *International journal of psychophysiology*, 63(1):48–54, 2007.
7. J Th Bigger, Joseph L Fleiss, Richard C Steinman, Linda M Rolnitzky, Robert E Kleiger, and Jeffrey N Rottman. Frequency domain measures of heart period variability and mortality after myocardial infarction. *Circulation*, 85(1):164–171, 1992.
8. B. McA Sayers. Analysis of heart rate variability. *Ergonomics*, 16(1):17–32, 1973.
9. Claude Julien. The enigma of mayer waves: facts and models. *Cardiovascular research*, 70(1):12–21, 2006.
10. JE Mietus, CK Peng, I Henry, RL Goldsmith, and AL Goldberger. The pnnx files: re-examining a widely used heart rate variability measure. *Heart*, 88(4):378–380, 2002.
11. Clinton F Goss and Eric B Miller. Dynamic metrics of heart rate variability. *arXiv preprint arXiv:1308.6018*, 2013.
12. Luiz Carlos Marques Vanderlei, Carlos Marcelo Pastre, Ismael Forte Freitas Júnior, and Moacir Fernandes de Godoy. Geometric indexes of heart rate variability in obese and eutrophic children. *Arquivos brasileiros de cardiologia*, 95(1):35–40, 2010.
13. C-K Peng, J Mietus, JM Hausdorff, S Havlin, H Eugene Stanley, and AL Goldberger. Long-range anticorrelations and non-gaussian behavior of the heartbeat. *Physical review letters*, 70(9):1343, 1993.
14. Jørgen K Kanters, NIELS-HENRIK HOLSTEIN-RATHLOU, and Erik Agner. Lack of evidence for low-dimensional chaos in heart rate variability. *Journal of cardiovascular electrophysiology*, 5(7):591–601, 1994.

15. PW Kamen and AM Tonkin. Application of the poincare plot to heart rate variability: a new measure of functional status in heart failure. *Australian and New Zealand journal of medicine*, 25(1):18–26, 1995.
16. Peter Grassberger and Itamar Procaccia. Measuring the strangeness of strange attractors. In *The Theory of Chaotic Attractors*, pages 170–189. Springer, 2004.
17. Jan W Kantelhardt, Eva Koscielny-Bunde, Henio HA Rego, Shlomo Havlin, and Armin Bunde. Detecting long-range correlations with detrended fluctuation analysis. *Physica A: Statistical Mechanics and its Applications*, 295(3):441–454, 2001.
18. Robert J Storella, Harrison W Wood, Kenneth M Mills, Jørgen K Kanters, Michael V Højgaard, and Niels-Henrik Holstein-Rathlou. Approximate entropy and point correlation dimension of heart rate variability in healthy subjects. *Integrative physiological and behavioral science*, 33(4):315–320, 1998.
19. Joshua S Richman and J Randall Moorman. Physiological time-series analysis using approximate entropy and sample entropy. *American Journal of Physiology-Heart and Circulatory Physiology*, 278(6):H2039–H2049, 2000.
20. Madalena Costa, Ary L Goldberger, and C-K Peng. Multiscale entropy analysis of complex physiologic time series. *Physical review letters*, 89(6):068102, 2002.
21. Boris P Kovatchev, Leon S Farhy, Hanqing Cao, M Pamela Griffin, Douglas E Lake, and J Randall Moorman. Sample asymmetry analysis of heart rate characteristics with application to neonatal sepsis and systemic inflammatory response syndrome. *Pediatric research*, 54(6):892–898, 2003.
22. Amir H Shirazi, Mohammad R Raoufy, Haleh Ebadi, Michele De Rui, Sami Schiff, Roham Mazloom, Sohrab Hajizadeh, Shahriar Gharibzadeh, Ahmad R Dehpour, Piero Amodio, et al. Quantifying memory in complex physiological time-series. *PloS one*, 8(9):e72854, 2013.
23. H Ebadi, AH Shirazi, Ali R Mani, and GR Jafari. Inverse statistical approach in heartbeat time series. *Journal of Statistical Mechanics: Theory and Experiment*, 2011(08):P08014, 2011.
24. Raúl Rojas. *Neural networks: a systematic introduction*. Springer Science & Business Media, 2013.
25. Alan Graves, Abdel-rahman Mohamed, and Geoffrey Hinton. Speech recognition with deep recurrent neural networks. In *Acoustics, Speech and Signal Processing (ICASSP), 2013 IEEE International Conference on*, pages 6645–6649. IEEE, 2013.
26. Ronaldo Messina and Jérôme Louradour. Segmentation-free handwritten chinese text recognition with lstm-rnn. In *Document Analysis and Recognition (ICDAR), 2015 13th International Conference on*, pages 171–175. IEEE, 2015.
27. Kyunghyun Cho, Bart Van Merriënboer, Caglar Gulcehre, Dzmitry Bahdanau, Fethi Bougares, Holger Schwenk, and Yoshua Bengio. Learning phrase representations using rnn encoder-decoder for statistical machine translation. *arXiv preprint arXiv:1406.1078*, 2014.
28. Sharat C Prasad and Piyush Prasad. Deep recurrent neural networks for time series prediction. *arXiv preprint arXiv:1407.5949*, 2014.
29. Sepp Hochreiter. The vanishing gradient problem during learning recurrent neural nets and problem solutions. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, 6(02):107–116, 1998.

30. Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, 9(8):1735–1780, 1997.
31. Michael C Mozer. A focused back-propagation algorithm for temporal pattern recognition. *Complex systems*, 3(4):349–381, 1989.